

University Name
Department of Computer Science

Generative AI in Journalism

A Field Study on Efficiency and Writing Style Changes
in AI-Assisted Journalism

Master's Thesis

submitted in partial fulfilment of the requirements
for the degree of *Master of Science in Computer Science*

Author: Simon Fierbeck
Student ID: 73261
Supervisor: Prof. Dr. Steffen Herbold

June 4, 2026

Declaration of Academic Integrity

I hereby declare that the thesis submitted is my own unaided work. All direct or indirect sources used are acknowledged as references. I am aware that the thesis in digital form can be examined for the use of unauthorised aid and in order to determine whether the thesis as a whole or parts incorporated in it may be deemed as plagiarism. For the comparison of my work with existing sources I agree that it shall be entered in a database where it shall also remain after examination, to enable comparison with future theses submitted.

Place, Date

Signature

Abstract

To do (??)

Keywords: Generative AI, Journalism, Field Study, Writing Style, Efficiency, Large Language Models, Natural Language Processing

Contents

List of Figures

List of Tables

Chapter 1

Introduction

To do (??)

1.1 Motivation

Modern Large Language Models (LLMs) like ChatGPT, Claude and Gemini are able to produce high quality written text. Supplied with the right information, in theory these LLMs should be able to produce journalistic articles. As journalists are also trained and experienced in writing informative articles based on core information about the subject. As the speed of journalism has increased through the need of competition because of the connected world through ethernet, lowering the time spend on an article creates buesiness value in itself. The speed in which generative artificial intelegince (AI) can produce text is unmatched compared to humans. But can a general purpose AI generate the quality of text, for which customers are willing to buy and read an article? Are journalists able to implement the AI in their workflow to decrease their time spend on an article?

In this study I try to mimic the process behind journalisitic work for an application powered by AI. This tool is supplied to an cooperating editorial team. This team includes journalists with varying levels of experience and from different editorial departments to be able to obtain a representative perspective on journalistic work practices. Over a specified perios these journalists will include the provided tool in their day to day work and protocoll their work with it. Throught that I want to analyze the advantages and disadvantages working with generative AI in a real world scenario.

1.2 Research Questions

The thesis investigates two core research questions:

RQ1 To what extent does the use of generative AI tools affect the working efficiency and article quality of journalists?

RQ2 What measurable changes in writing style can be observed when comparing AI-assisted text production to unassisted writing?

1.3 Thesis Structure

Was reingehört: Ein einleitender Satz, der den Gesamtaufbau ankündigt, gefolgt von einem Absatz (oder kurzen Sätzen) pro Kapitel – jeweils mit dem Kern-Inhalt, nicht nur dem Titel wiederholen. Beispiel für deine Arbeit:

The remainder of this thesis is structured as follows. Chapter 2 provides the necessary background on generative AI, large language models, and stylometric analysis methods. Chapter 3 reviews related work on AI in journalism, human–AI collaboration, and computational writing-style analysis, and identifies the research gap this thesis addresses. Chapter 4 describes the study design, the developed web application, participant recruitment, data collection procedures, and the analysis methods applied. Chapter 5 presents the results, covering efficiency metrics, writing-style features, and qualitative interview findings. Chapter 6 discusses and interprets these findings, addresses limitations and threats to validity. Chapter 7 concludes the thesis by summarizing contributions, answering the research questions, and outlining directions for future work.

Chapter 2

Background

To do (??)

2.1 Generative AI and Large Language Models

Gängige State of the Art AI Modelle wie Claude Sonnet[1], ChatGPT[2] und Gemini[3] basieren auf dem Transformer[4] Methode. Hier

2.2 Natural Language Processing for Stylometric Analysis

2.3 Journalistic Production Processes

Chapter 3

Related Work

To do (??)

3.1 AI in Journalism

3.2 Human–AI Collaboration in Knowledge Work

3.3 Computational Writing-Style Analysis

3.4 Research Gap

Chapter 4

Methodology

To do (??)

4.1 Study Design Overview

The field study follows a three-phase model:

1. **Phase 1 – Baseline (without AI assistance):** Participants produce journalistic texts without any generative AI tools, establishing baseline metrics.
2. **Phase 2 – Intervention (with AI assistance):** Participants use the custom web application with an integrated generative AI interface under comparable task conditions.
3. **Phase 3 – Qualitative Interview:** A semi-structured interview captures subjective perceptions, usage strategies, and critical reflections.

4.2 Web Application

4.2.1 Architecture

4.2.2 Logging and Metrics Collection

4.3 Participants

4.4 Data Collection

4.4.1 Quantitative Metrics

4.4.2 Qualitative Instruments

4.5 Data Analysis

4.5.1 Efficiency Analysis

4.5.2 Writing Style Analysis

4.6 Hypotheses

Based on the literature, the following hypotheses are proposed:

H_1 AI assistance leads to a statistically significant reduction in task completion time (RQ1).

H_2 AI-assisted texts exhibit measurable stylistic homogenisation across participants (RQ2).

4.7 Ethical Considerations

Chapter 5

Results

To do (??)

5.1 Efficiency Metrics

5.1.1 Task Completion Time

5.1.2 Perceived Text Quality

Task Completion Time Dein Ansatz ist richtig. Ein paar Ergänzungen: Normalisierung ist wichtig Rohe Zeit allein ist trügerisch — ein langer Artikel dauert immer länger. Du solltest also normalisieren, z.B.:

Zeit pro 100 Wörter Output Zeit pro Komplexitätsstufe (falls du Aufgaben vordefinierst)

Was du kontrollieren musst

Textlänge des Outputs Themen-/Aufgabenschwierigkeit (möglichst vergleichbare Tasks in Phase 1 und 2) Tageszeit / Ermüdungseffekte (falls relevant)

Zusätzlich interessant

Time-on-task Verteilung: Nicht nur Mittelwert, sondern auch Varianz — schreiben Journalisten mit KI gleichmäßiger? Edit-Rate: Wie viel wird nach KI-Generierung noch verändert? Das sagst du zwar nicht direkt, aber wenn deine App es loggt wäre es Gold wert.

Perceived Text Quality Hier wird es etwas kniffliger, weil "Qualität" subjektiv ist. Du brauchst eine klare Operationalisierung. Typische Ansätze: Selbsteinschätzung der Journalisten (einfach, aber subjektiv) Likert-Skala nach jeder Aufgabe, z.B.:

„Wie zufrieden sind Sie mit dem entstandenen Text?“ (1–5) „Wie sehr entspricht der Text Ihrem gewohnten Stil?“ (1–5)

Externe Bewertung (aufwändiger, aber objektiver) Redakteure oder andere Journalisten bewerten Texte blind — ohne zu wissen ob KI beteiligt war. Das wäre methodisch sehr stark. Automatische Qualitätsmetriken (als Ergänzung) Da du ohnehin NLP

machst, kannst du das verbinden:

Kohärenzscores (z.B. mit einem Language Model) Grammatikfehlerrate

5.2 Writing Style Analysis

5.2.1 Lexical Features

Lexikalische Features Type-Token-Ratio (TTR) / MATTR Misst lexikalische Vielfalt. MATTR (Moving Average TTR) ist robuster bei unterschiedlichen Textlängen — wichtig, weil Titel vs. Artikeltext riesige Längenunterschiede haben. Lexikalische Dichte Anteil der Inhaltswörter (Nomen, Verben, Adjektive, Adverbien) vs. Funktionswörter. KI-Texte tendieren oft zu höherer Dichte. Nominalstil-Index Verhältnis Nomen zu Verben. Journalismus hat traditionell hohen Nominalstil — verändert KI das? Durchschnittliche Wortlänge Wortfrequenz Einfach zu berechnen, aber aussagekräftig. KI-Modelle bevorzugen statistische Häufigkeit, also tendenziell häufigere Wörter. Hapax Legomena Rate Anteil Wörter, die nur einmal vorkommen — Maß für Originalität/Kreativität.

Syntaktische Features Durchschnittliche Satzlänge Klassiker. KI-Texte sind oft gleichmäßiger — das ist selbst ein Signal. Varianz der Satzlänge Genauso wichtig wie der Mittelwert. Menschen variieren stärker. Dependency-Tree-Tiefe Mit spaCy oder CoreNLP einfach berechenbar. Misst syntaktische Komplexität. Subordinationsgrad Verhältnis von Neben- zu Hauptsätzen. Tiefere Schachtelung = komplexerer Stil. POS-Tag-Distributionen Anteil Adjektive, Adverbien, Passivkonstruktionen etc. als Feature-Vektor — gut für maschinelles Lernen.

Stilistische / höherwertige Features Readability Scores Flesch-Kincaid, Gunning Fog, oder für Deutsch: Lesbarkeitsindex (LIX) oder Wiener Sachtextformel. Gut für Vergleich, weil leicht erklärbar. Stilhomogenisierung (dein Kern-Beitrag!) Das ist dein stärkstes Argument: Schreiben verschiedene Journalisten ähnlicher, wenn sie KI nutzen? Du könntest paarweise Cosine-Similarity zwischen Autoren berechnen — wenn die Varianz zwischen Autoren in Phase 2 sinkt, ist das ein starkes Ergebnis. Sentiment Emotionalität Mit Lexikon-basierten Tools (z.B. VADER, SentiWS für Deutsch) — verändert KI den emotionalen Ton?

Statistische Auswertung Da du gepaarte Messungen hast (selber Journalist, Phase 1 vs. Phase 2), bieten sich an:

Wilcoxon-Vorzeichen-Rang-Test (non-parametrisch, kleine Stichprobe) Paired t-Test wenn Normalverteilung annehmbar Cohen's d für Effektgröße PCA oder t-SNE um Texte im Feature-Raum zu visualisieren — sehr überzeugend für die Homogenisierungs-These

Tool-Empfehlungen ToolSpracheFür wasspaCyPythonPOS-Tagging, Dependency ParsingNLTKPythonTTR, TokenisierungtextstatPythonReadability ScoresSentiWS / VADERPythonSentimentscikit-learnPythonCosine Similarity, PCAR (stylo pack-

age)RStilometrie, speziell für Autorenvergleich

5.2.2 Syntactic Features

5.2.3 Readability

5.3 Qualitative Interview Findings

Chapter 6

Discussion

To do (??)

6.1 Interpretation of Efficiency Results

6.2 Interpretation of Writing Style Changes

6.3 Synthesis of Quantitative and Qualitative Findings

6.4 Limitations

6.5 Threats to Validity

Chapter 7

Conclusion & Future Work

To do (??)

7.1 Summary of Contributions

7.2 Answers to Research Questions

7.3 Future Work

References

- [1] G. Team et al., *Gemini: A family of highly capable multimodal models*, 2025. arXiv: [2312.11805](https://arxiv.org/abs/2312.11805) [cs.CL]. [Online]. Available: <https://arxiv.org/abs/2312.11805>
- [2] A. Singh et al., *Openai gpt-5 system card*, 2026. arXiv: [2601.03267](https://arxiv.org/abs/2601.03267) [cs.CL]. [Online]. Available: <https://arxiv.org/abs/2601.03267>
- [3] “The claude 3 model family: Opus, sonnet, haiku. ”[Online]. Available: <https://api.semanticscholar.org/CorpusID:268232499>
- [4] A. Vaswani et al., *Attention is all you need*, 2023. arXiv: [1706.03762](https://arxiv.org/abs/1706.03762) [cs.CL]. [Online]. Available: <https://arxiv.org/abs/1706.03762>

Appendix A

Web Application Documentation

To do (??)

Appendix B

Study Materials

B.1 Participant Information Sheet

B.2 Consent Form

B.3 Interview Guide

Appendix C

Supplementary Data

To do (??)